BỘ NÔNG NGHIỆP VÀ MÔI TRƯỜNG

PHÂN HIỆU TRƯỜNG ĐẠI HỌC THỦY LỢI

BỘ MÔN CÔNG NGHỆ THÔNG TIN

BÁO CÁO MÔN: TRỰC QUAN HÓA DỮ LIỆU

TÊN ĐỀ TÀI: PHÂN TÍCH CẢM XÚC KHÁCH HÀNG QUA BÌNH LUẬN TRÊN SÀN THƯƠNG MẠI ĐIỆN TỬ

Giảng viên:	TS. Hoàng Văn Quý
Sinh viên thực hiện:	2351267275 - Nguyễn Văn Tấn Phát 2351267271 – Nguyễn Hoàng Lộc
Lớp:	S26-65TTNT

TP. Hồ Chí Minh, ngày … tháng … năm 2026

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....
.....

TP. Hồ Chí Minh, ngày … tháng … năm 2025

Chữ ký của giảng viên

LỜI CẢM ƠN

Em xin chân thành cảm ơn TS. Hoàng Văn Quý – giảng viên phụ trách môn học – đã tận tình giảng dạy, hướng dẫn và hỗ trợ em trong suốt quá trình học tập. Những kiến thức chuyên môn, phương pháp tiếp cận vấn đề và sự chỉ dẫn của cô đã giúp em hiểu rõ hơn nội dung môn học và hoàn thành bài báo cáo đúng yêu cầu.

Mặc dù đã cố gắng hết sức, bài làm của em vẫn khó tránh khỏi những thiếu sót do thời gian và kinh nghiệm còn hạn chế. Em rất mong nhận được những nhận xét và góp ý từ cô để có thể hoàn thiện hơn kiến thức và kỹ năng của mình.

Em xin chân thành cảm ơn cô!

MỤC LỤC

LỜI CẢM ƠN 2
CHƯƠNG 1: GIỚI THIỆU & MỤC TIÊU DỰ ÁN 7
1.1. Đặt vấn đề 7
1.2. Mục tiêu dự án 7
1.3. Phạm vi nghiên cứu 7
1.4. Phương pháp thực hiện 8
1.5. Ý nghĩa của đề tài 8
1.6. Cấu trúc báo cáo 8
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT & QUY TẮC TRỰC QUAN HÓA 9
2.1. Tổng quan về Phân tích cảm xúc (Sentiment Analysis) 9
2.2. Vai trò của trực quan hóa dữ liệu 9
2.3. Lý thuyết về các dạng biểu đồ trong trực quan hóa dữ liệu 10
2.4. Các nguyên tắc trực quan hóa dữ liệu chuyên nghiệp 11
CHƯƠNG 3: HỆ THỐNG TIỀN XỬ LÝ DỮ LIỆU 13
3.1. Tổng quan về quy trình tiền xử lý 13
3.2. Chuẩn hóa mã hóa và dọn dẹp nhiễu văn bản 13
3.3. Xử lý biểu tượng cảm xúc và chuẩn hóa trực quan từ vựng 14
3.4. Lọc chất lượng và chiến lược chia tách tập dữ liệu 14
CHƯƠNG 4: PHÂN TÍCH TRỰC QUAN VÀ RÚT RA INSIGHT 16
4.1. Tổng quan quy mô và tính ổn định của tập dữ liệu 16
4.2. Phân tích độ dài văn bản và thiết lập cấu hình mô hình 17
4.3. Phân tích độ phủ lớp và mật độ gán nhãn khía cạnh 17
4.4. Phân tích đa nhãn và tương quan cảm xúc 19
4.5. Khai phá tri thức từ vựng qua PMI và Đám mây từ ngữ 20
4.6. Trực quan với không gian embedding 25

CHƯƠNG 5 THỰC NGHIỆM, ĐÁNH GIÁ MÔ HÌNH VÀ PHÂN TÍCH SAI LỖI 28
5.1. Thiết lập thực nghiệm 28
5.2. Các mô hình thực nghiệm 28
5.3. Độ đo và Quy trình huấn luyện 29
5.4. Kết quả thực nghiệm và Thảo luận 30
5.5. Tối ưu hóa và Phân tích sai lỗi 32
CHƯƠNG 6: XÂY DỰNG DASHBOARD VÀ ỨNG DỤNG THỰC TẾ.....34
6.1. Mục tiêu và Công cụ phát triển 34
6.2. Các chức năng chính của hệ thống.....34
6.3. Hình ảnh giao diện thực tế 35
HƯƠNG 7: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 36
7.1. Kết quả đạt được 36
7.2. Hạn chế.....36
7.3. Hướng phát triển 36
TÀI LIỆU THAM KHẢO.....37

DANH MỤC HÌNH ẢNH

hình 1 Tổng quan tập dữ liệu 16

hình 2 thống kê phân phối nhãn giữa 3 tập dữ liệu train/val/test.....16

hình 3 biểu đồ Histogram + KDE độ dài review 17

hình 4 Biểu đồ Heatmap tỉ lệ thiếu theo split x sentiment / aspect.....18

hình 5 biểu đồ Lollipop Chart độ phủ nhãn theo aspect 18

hình 6 biểu đồ cột thể hiện phân bố số aspect / review.....19

hình 7 biểu đồ stacked bar chart thể hiện cơ cấu sentiment trong từng aspect 20

hình 8 biểu đồ Word Cloud thể hiện từ khóa tương ứng với từng sentiment ..20

hình 9 biểu đồ Word Cloud thể hiện tần suất xuất hiện trong từng aspect.....21

hình 10 Biểu đồ Diverging Bar Chart thể hiện PMI khác biệt Positive vs Negative 22

hình 11 biểu đồ Heatmap thể hiện ma traian PMI của 50 term nổi bật nhất ...23

hình 12 biểu đồ network graph / co-occurrence network thể hiện mối liên kết từ ngữ và cảm xúc 24

hình 13 biểu đồ scatter plot thể hiện không gian embedding màu theo sentiment 25

hình 14 biểu đồ scatter plot thể hiện không gian embedding màu theo aspect chi phối.....26

hình 15 hình ảnh Hệ thống Phân tích Sắc thái 35

hình 16 hình ảnh Bảng điều khiển Kiểm tra dữ liệu 35

DANH MỤC BẢNG

Bảng 1 Tổng Quan 3 tập dữ liệu Train-Valid-Test 28

Bảng 2 Tổng quan 4 mô hình chính 28

Bảng 3 Các cấu hình siêu tham số chính 30

Bảng 4 Kết quả so sánh các experiment của notebook PhoBERT trên tập validation 30

Bảng 5 So sánh hiệu năng tổng thể giữa các mô hình 30

Bảng 6 Macro-F1 theo 6 khía cạnh trên tập test 31

Bảng 7 Bảng 5.7. Ngưỡng presence tối ưu của PhoBERT trên tập validation .32

Bảng 8 Xếp hạng khía cạnh theo số lỗi được ghi nhận trong notebook PhoBERT 32

CHƯƠNG 1: GIỚI THIỆU & MỤC TIÊU DỰ ÁN

1.1. Đặt vấn đề

Sự phát triển của các sàn thương mại điện tử như Tiki tạo ra lượng lớn bình luận từ khách hàng sau khi mua sản phẩm. Các bình luận này phản ánh trực tiếp mức độ hài lòng của người dùng về nhiều khía cạnh như chất lượng sản phẩm, giá cả, giao hàng, đóng gói và dịch vụ. Tuy nhiên, do số lượng dữ liệu lớn và nội dung bình luận thường ngắn, không chuẩn hóa, nhiều cảm xúc đan xen, việc phân tích thủ công gặp nhiều khó khăn.

Vì vậy, cần có một hệ thống tự động giúp phân tích cảm xúc khách hàng từ dữ liệu bình luận, từ đó hỗ trợ doanh nghiệp hiểu rõ nhu cầu người dùng và nâng cao chất lượng dịch vụ.

1.2. Mục tiêu dự án

Dự án hướng đến xây dựng hệ thống phân tích cảm xúc khách hàng qua bình luận trên sàn thương mại điện tử theo hướng ABSA (Aspect-Based Sentiment Analysis).

Các mục tiêu chính gồm:

- Thu thập, làm sạch và chuẩn hóa dữ liệu bình luận.
- Phân tích dữ liệu để xác định đặc điểm, xu hướng và các vấn đề của tập dữ liệu.
- Xây dựng mô hình nhận diện khía cạnh và cảm xúc trong từng bình luận.
- Đánh giá hiệu quả mô hình bằng các chỉ số phù hợp.
- Xây dựng giao diện trực quan để hỗ trợ quan sát dữ liệu và kết quả dự đoán.

1.3. Phạm vi nghiên cứu

Đề tài tập trung vào dữ liệu review sách trên sàn Tiki. Nội dung nghiên cứu chủ yếu xoay quanh:

- Bình luận văn bản tiếng Việt của khách hàng.
- Các khía cạnh như: nội dung, chất lượng sách, giá cả, đóng gói, giao hàng và dịch vụ.
- Quy trình từ tiền xử lý dữ liệu, trực quan hóa dữ liệu, huấn luyện mô hình đến triển khai dashboard.

Đề tài chưa mở rộng sang các ngành hàng khác và chưa triển khai ở quy mô hệ thống thương mại thực tế.

1.4. Phương pháp thực hiện

Dự án được thực hiện theo quy trình gồm các bước:

- Thu thập và chuẩn bị dữ liệu bình luận.
- Tiền xử lý văn bản tiếng Việt.
- Trực quan hóa và phân tích dữ liệu.
- Xây dựng mô hình ABSA.
- Đánh giá kết quả mô hình.
- Triển khai dashboard minh họa kết quả.

Cách tiếp cận của đề tài là dùng trực quan hóa dữ liệu để hỗ trợ quá trình xây dựng và cải thiện mô hình, giúp việc phát triển hệ thống có cơ sở rõ ràng hơn.

1.5. Ý nghĩa của đề tài

Đề tài có ý nghĩa thực tiễn và học thuật rõ rệt. Về thực tiễn, hệ thống giúp tự động tổng hợp ý kiến khách hàng, hỗ trợ nhà bán hàng và doanh nghiệp phát hiện nhanh các vấn đề trong sản phẩm và dịch vụ. Về học thuật, đề tài là sự kết hợp giữa xử lý ngôn ngữ tự nhiên, học máy và trực quan hóa dữ liệu trong bài toán thực tế bằng tiếng Việt.

1.6. Cấu trúc báo cáo

Báo cáo gồm 6 chương:

- Chương 1: Giới thiệu và mục tiêu dự án.
- Chương 2: Cơ sở lý thuyết và quy tắc trực quan hóa.
- Chương 3: Hệ thống tiền xử lý dữ liệu.
- Chương 4: Phân tích trực quan và rút ra insight.
- Chương 5: Phát triển và đánh giá mô hình.
- Chương 6: Triển khai dashboard ứng dụng.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT & QUY TẮC TRỰC QUAN HÓA

2.1. Tổng quan về Phân tích cảm xúc (Sentiment Analysis)

Phân tích cảm xúc, hay còn được gọi là Opinion Mining (khai thác quan điểm), là một lĩnh vực nghiên cứu chuyên sâu thuộc Xử lý ngôn ngữ tự nhiên (NLP) tập trung vào việc tự động nhận diện, trích xuất và định lượng các trạng thái chủ quan, quan điểm và thái độ của con người thể hiện qua văn bản. Về mặt lý thuyết, một quan điểm thường được mô tả bởi một bộ ngũ (five-tuple) bao gồm: Thực thể (Entity), Khía cạnh (Aspect), Cảm xúc (Sentiment), Người đưa ra quan điểm (Opinion Holder) và Thời điểm (Time). Nhiệm vụ cốt lõi của phân tích cảm xúc là xác định giá trị sắc thái (Polarity) – thường được phân loại thành Tích cực (Positive), Tiêu cực (Negative) hoặc Trung lập (Neutral) – để chuyển đổi dữ liệu phi cấu trúc thành thông tin có ý nghĩa thống kê.

Trong tiến trình phát triển của phân tích cảm xúc, bài toán được triển khai ở nhiều cấp độ tinh vi khác nhau tùy thuộc vào phạm vi của văn bản đầu vào. Ở cấp độ văn bản (Document-level), mô hình tìm cách xác định cảm xúc chung cho toàn bộ nội dung; trong khi đó, cấp độ câu (Sentence-level) đi sâu vào việc đánh giá sắc thái cảm xúc của từng câu riêng lẻ. Tuy nhiên, cấp độ tinh vi nhất và mang lại giá trị tri thức sâu sắc nhất là Phân tích cảm xúc dựa trên khía cạnh (Aspect-Based Sentiment Analysis - ABSA). ABSA cho phép bóc tách cảm xúc đối với từng đặc tính cụ thể của thực thể, giúp tránh được những sai lệch khi một câu văn chứa đựng nhiều luồng ý kiến trái ngược cho các thuộc tính khác nhau. Lý thuyết về ABSA bao gồm hai nhiệm vụ chính yếu: nhận diện khía cạnh chủ đề (Aspect Category Detection) và phân loại cảm xúc gắn

2.2. Vai trò của trực quan hóa dữ liệu

Trực quan hóa dữ liệu không chỉ đơn thuần là việc trình bày kết quả cuối cùng mà còn được coi là một phương thức tư duy quan yếu trong quy trình khoa học dữ liệu hiện đại. Về khía cạnh lý thuyết, trực quan hóa dữ liệu là quá trình chuyển đổi dữ liệu thô từ dạng số và văn bản phi cấu trúc sang các biểu đồ, đồ thị và hình ảnh tương tác nhằm khai thác các mô hình (patterns), xu hướng (trends) và sự tương quan (correlations) mà các phương pháp thống kê thuần túy khó có thể diễn đạt hết. Trực quan hóa dữ liệu đóng vai trò then chốt trong giai đoạn Phân tích dữ liệu khám phá

(Exploratory Data Analysis - EDA), cho phép nhà phân tích hiểu sâu sắc về cấu trúc và phân bố của tập dữ liệu trước khi thực hiện các bước xây dựng mô hình học máy phức tạp.

Một trong những minh chứng điển hình cho vai trò của trực quan hóa là bộ tứ Anscombe (Anscombe's Quartet). Đây là ví dụ kinh điển trong khoa học thống kê, chỉ ra rằng bốn tập dữ liệu có các chỉ số mô tả gần như tương đồng (như trung bình, phương sai, tương quan và đường hồi quy) nhưng lại có cấu trúc phân bố hoàn toàn khác biệt khi được biểu diễn trên biểu đồ phân tán. Điều này khẳng định rằng việc chỉ dựa vào các chỉ số thống kê tổng hợp có thể dẫn đến những kết luận sai lệch về bản chất của dữ liệu. Trong bối cảnh phân tích cảm xúc, trực quan hóa giúp nhận diện ngay lập tức tình trạng mất cân bằng nhãn (Class Imbalance) – một vấn đề phổ biến có thể làm sai lệch hiệu năng của mô hình AI, đồng thời hỗ trợ phát hiện các điểm dữ liệu bất thường (Outliers) và các lỗi mã hóa văn bản ẩn sâu trong tập dữ liệu thô.

Ngoài mục đích phân tích kỹ thuật, trực quan hóa còn đóng vai trò là công cụ truyền tải thông tin mạnh mẽ (Storytelling with Data) và hỗ trợ ra quyết định. Bằng việc mã hóa các thuộc tính cảm xúc phức tạp sang các biểu đồ radar, bản đồ nhiệt hay các dải màu trực quan, hệ thống giúp đơn giản hóa các luồng dữ liệu dày đặc thành những tri thức dễ tiếp cận. Sự kết hợp giữa trực quan hóa và trí tuệ nhân tạo tạo nên một quy trình làm việc minh bạch, nơi người dùng có thể quan sát trực tiếp các xác suất dự đoán của mô hình và hiểu rõ được các khía cạnh chủ chốt đang chi phối thái độ của khách hàng. Cuối cùng, trực quan hóa chính là cầu nối quan trọng giúp chuyển hóa các kết quả tính toán cơ học thành các insights có giá trị thực tiễn, hỗ trợ doanh nghiệp trong việc cải thiện chất lượng dịch vụ và tối ưu hóa trải nghiệm người dùng một cách có cơ sở.với khía cạnh đó (Aspect Sentiment Classification).

2.3. Lý thuyết về các dạng biểu đồ trong trực quan hóa dữ liệu

Trong khoa học dữ liệu, việc lựa chọn dạng biểu đồ không chỉ dựa trên tính thẩm mỹ mà phải tuân theo các nguyên lý về tri giác thị giác và đặc tính của biến số. Đối với việc phân tích mật độ và mối tương quan giữa các chiều dữ liệu, bản đồ nhiệt (Heatmap) là công cụ lý thuyết mạnh mẽ bậc nhất. Về mặt nguyên lý, bản đồ nhiệt sử dụng một thang phổ màu (color scale) để mã hóa các giá trị định lượng trong một ma trận hai chiều. Khả năng phát hiện các "vùng nóng" (hotspots) giúp nhà phân tích

nhận diện nhanh chóng các cấu trúc dữ liệu bị thưa thớt (sparsity) hoặc các cụm dữ liệu tập trung mà không cần quan sát từng con số thống kê riêng lẻ.

Đối với bài toán so sánh tần suất các biến định tính, biểu đồ cột (Bar Chart) và các biến thể hiện đại như biểu đồ Lollipop đóng vai trò chủ đạo. Về lý thuyết, biểu đồ cột tận dụng khả năng của mắt người trong việc so sánh độ dài chính xác hơn so với diện tích hay góc độ. Biểu đồ Lollipop là một sự cải tiến về mặt hình thái, sử dụng một đường kẻ mảnh kết hợp với một điểm nút ở đầu nhằm tối đa hóa tỷ lệ dữ liệu trên mực vẽ (data-ink ratio). Việc tinh giản không gian đồ họa này giúp giảm tải trọng nhận thức cho người xem, trong khi vẫn đảm bảo tính chính xác trong việc định vị giá trị trên các trục tọa độ.

Khi nghiên cứu về phân bố của các biến định lượng liên tục, biểu đồ tần suất (Histogram) kết hợp với đường ước lượng mật độ nhân (Kernel Density Estimate - KDE) cung cấp cái nhìn tổng thể về hình dáng của dữ liệu. Histogram chia dữ liệu thành các dải (bins) để quan sát tần suất, giúp xác định các đặc tính quan trọng như độ lệch (skewness) hay độ nhọn (kurtosis). Đường KDE, một kỹ thuật làm mịn dữ liệu dựa trên hàm nhân, cho phép mô tả hình dáng phân bố một cách liên tục, giúp nhà phân tích kiểm chứng giả định về phân bố chuẩn hoặc phát hiện các giá trị ngoại lệ tiềm ẩn. Cuối cùng, trong lĩnh vực khai thác dữ liệu văn bản, kỹ thuật đám mây từ ngữ (Word Cloud) và bảng tần suất từ vựng được sử dụng để trực quan hóa tầm quan trọng của các thuật ngữ. Về mặt lý thuyết, việc thay đổi trọng số kích thước của từ dựa trên tần suất hoặc các chỉ số liên kết (như PMI) là một phương thức tóm lược thị giác hiệu quả, giúp chuyển đổi dữ liệu định tính không cấu trúc thành các cấu trúc có thể hiểu được ở góc độ thống kê.

2.4. Các nguyên tắc trực quan hóa dữ liệu chuyên nghiệp

Để đảm bảo tính trung thực và hiệu quả trong việc truyền đạt thông tin, lý thuyết về trực quan hóa dữ liệu dựa trên các nguyên lý khoa học thị giác và tâm lý học nhận thức. Nguyên tắc cốt cốt lõi được đề xướng bởi Edward Tufte là tối đa hóa tỷ lệ dữ liệu trên mực vẽ (Data-Ink Ratio). Theo đó, một biểu đồ khoa học cần loại bỏ triệt để các yếu tố gây nhiễu nhận thức, hay còn gọi là "chartjunk" (các lưới biểu đồ quá dày, hiệu ứng đổ bóng hoặc 3D không cần thiết), nhằm tập trung sự chú ý của người xem vào các thông điệp cốt lõi của dữ liệu. Bên cạnh đó, việc áp dụng các nguyên lý

Gestalt về sự gần gũi, sự tương đồng và tính liên tục giúp người đọc tự động nhận diện các mối quan hệ logic giữa các nhóm dữ liệu mà không cần thông qua các chỉ dẫn văn bản phức tạp.

Màu sắc trong trực quan hóa dữ liệu không chỉ đơn thuần là yếu tố thẩm mỹ mà là một phương thức mã hóa thông tin (Color Encoding). Việc sử dụng các thang màu có tính hệ thống như thang màu tương phản cho dữ liệu định tính và thang màu chuyển tiếp (sequential/diverging) cho dữ liệu định lượng là điều kiện tiên quyết để tránh gây hiểu lầm. Đặc biệt, trong bài toán phân tích sắc thái cảm xúc, việc thống nhất một bảng màu ngữ nghĩa (semantic color palette) trên toàn bộ hệ thống giúp người xem hình thành phản xạ nhận thức nhanh hơn về các trạng thái tiêu cực hoặc tích cực. Cuối cùng, tính nhất quán về kiểu chữ, kích thước tiêu đề và các nhãn trục (axis labels) trên mọi khung hình tạo nên sự liên kết logic xuyên suốt, giúp biến quá trình quan sát dữ liệu thành một câu chuyện có chiều sâu (Data Storytelling), hỗ trợ tối đa cho việc ra quyết định dựa trên bằng chứng khoa học.

CHƯƠNG 3: HỆ THỐNG TIỀN XỬ LÝ DỮ LIỆU

Quy trình thu thập và gán nhãn dữ liệu: Dự án bắt đầu bằng việc xây dựng bộ công cụ crawler để thu thập hàng nghìn đánh giá thực tế từ sàn thương mại điện tử Tiki, sau đó tiến hành bước gán nhãn thủ công (Manual Annotation) cho tập dữ liệu thô. Nhóm thực hiện đã xác lập 06 khía cạnh cốt lõi (Nội dung, Hình thức, Giá cả, Đóng gói, Giao hàng, Dịch vụ) và gán các sắc thái cảm xúc tương ứng (Tiêu cực, Trung lập, Tích cực) cho từng khía cạnh đó. Để đảm bảo độ tin cậy và khách quan, quy trình gán nhãn được thực hiện qua hai vòng kiểm tra chéo (Cross-check) giữa các thành viên Phát và Lộc, đồng thời áp dụng các bộ lọc chất lượng để loại bỏ các bình luận rác hoặc quá ngắn. Kết quả là một tập dữ liệu "Gold Standard" đạt độ chuẩn hóa cao về ngữ nghĩa, cung cấp nền tảng tri thức vững chắc cho việc huấn luyện và đánh giá các mô hình học sâu ở các giai đoạn tiếp theo.

3.1. Tổng quan về quy trình tiền xử lý

Tiền xử lý văn bản là giai đoạn then chốt nhằm chuyển đổi dữ liệu thô từ các bình luận trên sàn thương mại điện tử Tiki thành định dạng dữ liệu chuẩn, sẵn sàng cho việc huấn luyện mô hình học sâu. Do đặc thù ngôn ngữ người dùng thường mang tính informal (phi chuẩn hóa), pipeline tiền xử lý được thiết kế theo cấu trúc module hóa độc lập, cho phép xử lý đa tầng từ mức độ ký tự, từ vựng cho đến cấu trúc tập dữ liệu. Mục tiêu cốt lõi là loại bỏ tối đa các thành phần gây nhiễu nhưng vẫn bảo toàn được các tín hiệu cảm xúc quan trọng của khách hàng.

3.2. Chuẩn hóa mã hóa và dọn dẹp nhiễu văn bản

Giai đoạn này tập trung vào việc làm sạch bề mặt văn bản thông qua hai kỹ thuật chính:

- Chuẩn hóa Unicode (NFC Normalization): Giải quyết triệt để tình trạng không nhất quán về bảng mã giữa các bộ gõ tiếng Việt phổ biến (như Unikey, VietKey). Bằng cách đưa toàn bộ nội dung về chuẩn NFC (Normal Form Composed), hệ thống đảm bảo mỗi từ chỉ có một đại diện nhị phân duy nhất, giúp mô hình PhoBERT tối ưu hóa lớp nhúng (embeddings) và tránh làm loãng bộ từ điển.
- Làm sạch nhiễu (Noise Cleaning): Áp dụng các biểu thức chính quy (Regular Expressions) để loại bỏ các thành phần rác không mang giá trị ngữ nghĩa bao gồm: thẻ HTML, URL, địa chỉ email và các ký tự đặc biệt gây nhiễu. Đặc

biệt, module này thực hiện xử lý "elongated text" – rút gọn các chuỗi ký tự lặp lại quá mức (ví dụ: "đẹpppp" -> "đẹp") để quy đổi các biến thể cảm xúc về dạng từ điển chuẩn.

3.3. Xử lý biểu tượng cảm xúc và chuẩn hóa trực quan từ vựng

Để đối phó với sự phổ biến của ngôn ngữ mạng và các ký hiệu hình ảnh, dự án triển khai quy trình xử lý chuyên sâu:

- Chuẩn hóa Emoji (Emoji Normalization): Thay vì loại bỏ hoàn toàn, hệ thống thực hiện ánh xạ các emoji sang các token văn bản gợi nhớ (ví dụ: ❤️ -> "thả_tim"). Điều này đặc biệt quan trọng trong bài toán ABSA vì các biểu tượng cảm xúc thường mang trọng số rất cao trong việc xác định sắc thái cho các khía cạnh.
- Chuẩn hóa Teencode và Từ viết tắt (Vocab Normalization): Sử dụng bộ từ điển tra cứu tự xây dựng để "phục hồi" các từ vựng viết tắt phổ biến trong giao dịch mua bán như: sp (sản phẩm), k/ko (không), ship (giao hàng), rep (phản hồi),... Việc chuẩn hóa này giúp thu hẹp khoảng cách ngữ nghĩa giữa ngôn ngữ nói và ngôn ngữ chuẩn, tăng độ chính xác cho nhiệm vụ nhận diện khía cạnh chi tiết.

3.4. Lọc chất lượng và chiến lược chia tách tập dữ liệu

Công đoạn cuối cùng nhằm đảm bảo tính toàn vẹn và độ tin cậy cho quá trình đánh giá mô hình:

- Quality Filter: Thực hiện loại bỏ triệt để các bản ghi trùng lặp (deduplication) phát sinh trong quá trình thu thập và lọc bỏ các bình luận có độ dài dưới 3 từ. Các mẫu dữ liệu này thường không mang đủ ngữ cảnh để xác định khía cạnh, dễ gây nhiễu cho hàm mất mát (loss function) khi huấn luyện.
- Chiến lược Split dữ liệu: Tập dữ liệu tổng thể được chia tách theo tỷ lệ 70% dành cho huấn luyện (Train), 15% cho kiểm định (Validation) và 15% cho thử nghiệm (Test). Hệ thống áp dụng kỹ thuật Stratified Splitting dựa trên cả độ dài văn bản và phân bố nhãn cảm xúc. Phương pháp này đảm bảo các đặc điểm phân phối (distribution) giữa 03 tập dữ liệu là đồng nhất, giúp mô hình đạt được khả năng tổng quát hóa (generalization) tốt nhất khi triển khai thực tế.

CHƯƠNG 4: PHÂN TÍCH TRỰC QUAN VÀ RÚT RA INSIGHT

4.1. Tổng quan quy mô và tính ổn định của tập dữ liệu

Sau giai đoạn tiền xử lý, dự án tiến hành đánh giá quy mô và sự phân bổ dữ liệu trên các tập chia tách (Train/Val/Test). Đây là bước kiểm chứng quan trọng để đảm bảo kết quả thực nghiệm có tính tổng quát hóa cao.

	Tổng review	Train	Val	Test	Tỷ lệ tiêu cực	Tỷ lệ trung lập	Tỷ lệ tích cực
0	13,374	9,360	2,009	2,005	52.3%	16.2%	31.5%

hình 1 Tổng quan tập dữ liệu

Dựa trên số liệu thống kê, tổng tập dữ liệu bao gồm hơn 13,300 mẫu. Quy trình chia tách được thực hiện theo hướng Stratified, đảm bảo tỷ lệ các nhãn cảm xúc gần như đồng nhất giữa ba tập.

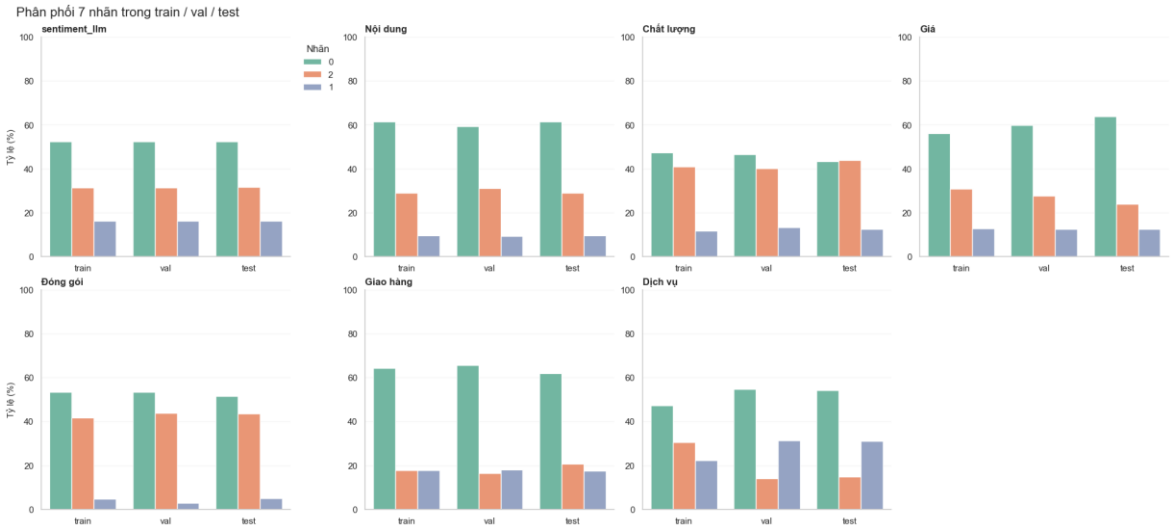

hình 2 thống kê phân phối nhãn giữa 3 tập dữ liệu train/val/test

Sự tương đồng về hình dáng biểu đồ qua 3 split khẳng định quy trình lấy mẫu không gây ra hiện tượng lệch phân phối (distribution shift), cho phép các chỉ số đánh giá trên tập Test phản ánh thực chất hiệu năng của mô hình.

4.2. Phân tích độ dài văn bản và thiết lập cấu hình mô hình

Việc hiểu rõ phân bố độ dài câu giúp xác định các tham số đầu vào cho kiến trúc PhoBERT và xử lý các trường hợp ngoại lệ.

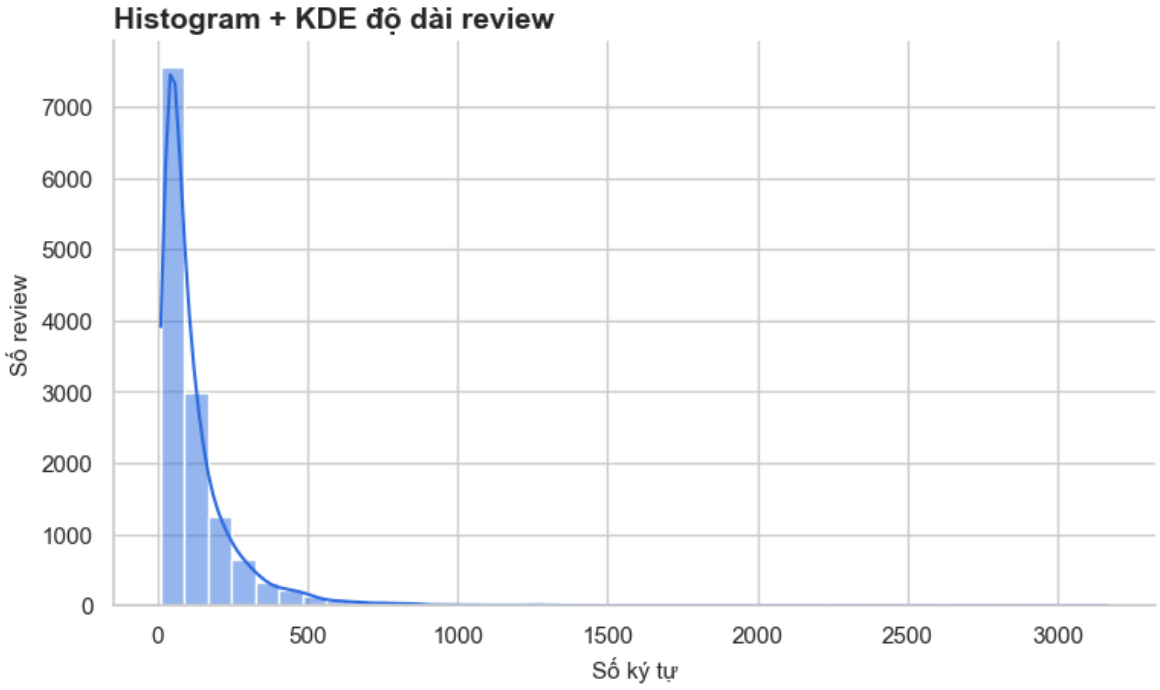

hình 3 biểu đồ Histogram + KDE độ dài review

Kết quả trực quan hóa cho thấy phân bố độ dài có dạng lệch phải (right-skewed). từ.

Insight: Đa số khách hàng trên Tiki viết bình luận ngắn gọn nhưng súc tích. Tuy nhiên, sự xuất hiện của các bình luận dài (long-tail) đòi hỏi mô hình phải có cơ chế cắt câu (padding & truncation) ở mức 128 hoặc 256 tokens để tối ưu hóa bộ nhớ mà vẫn không làm mất thông tin hữu ích.

4.3. Phân tích độ phủ lớp và mật độ gán nhãn khía cạnh

Thách thức lớn nhất của bài toán ABSA là mật độ gán nhãn thưa thớt. Biểu đồ Heatmap và Lollipop dưới đây mô tả chi tiết mức độ thiếu hụt dữ liệu trên từng khía cạnh.

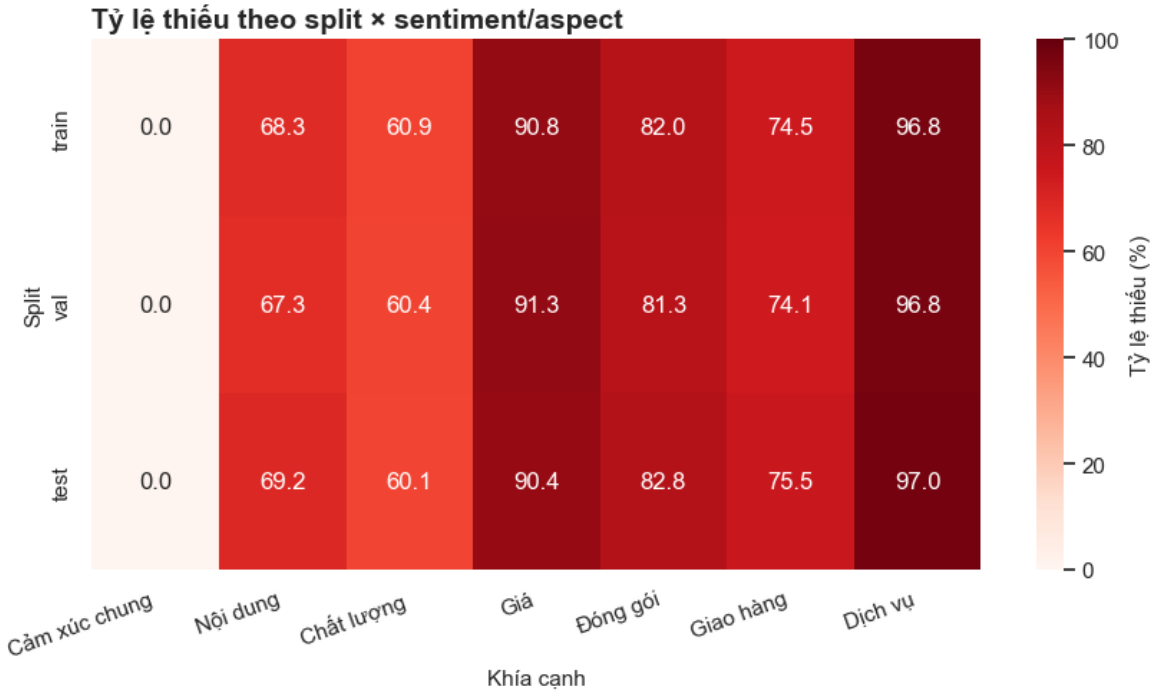

hình 4 Biểu đồ Heatmap tỉ lệ thiếu theo split x sentiment / aspect

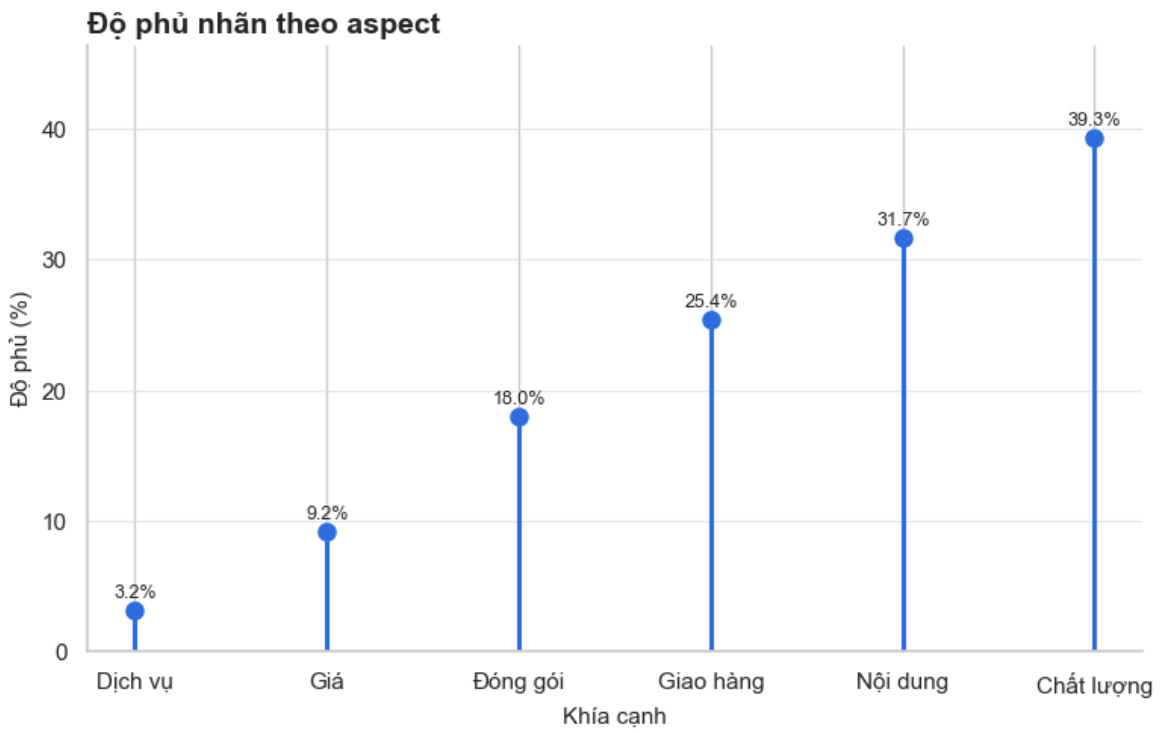

hình 5 biểu đồ Lollipop Chart độ phủ nhãn theo aspect

Kết quả: Hai khía cạnh có độ phủ tốt nhất là Chất lượng vật lý (~39.3%) và Nội dung (~31.7%). Ngược lại, khía cạnh Dịch vụ chỉ chiếm 3.2%, tạo nên một "vùng trũng" về dữ liệu.

Insight: Mô hình cần được giám sát kỹ lưỡng khi dự đoán các khía cạnh thiểu số. Kết quả trực quan hóa này là cơ sở để nhóm thực hiện áp dụng các kỹ thuật cân bằng dữ liệu hoặc điều chỉnh ngưỡng (threshold calibration) riêng cho từng khía cạnh nhằm tăng chỉ số Macro-F1.

4.4. Phân tích đa nhãn và tương quan cảm xúc

Biểu đồ dưới đây thống kê số lượng khía cạnh trung bình xuất hiện trong một bình luận, giúp đánh giá độ phức tạp của nhiệm vụ Multi-label Classification.

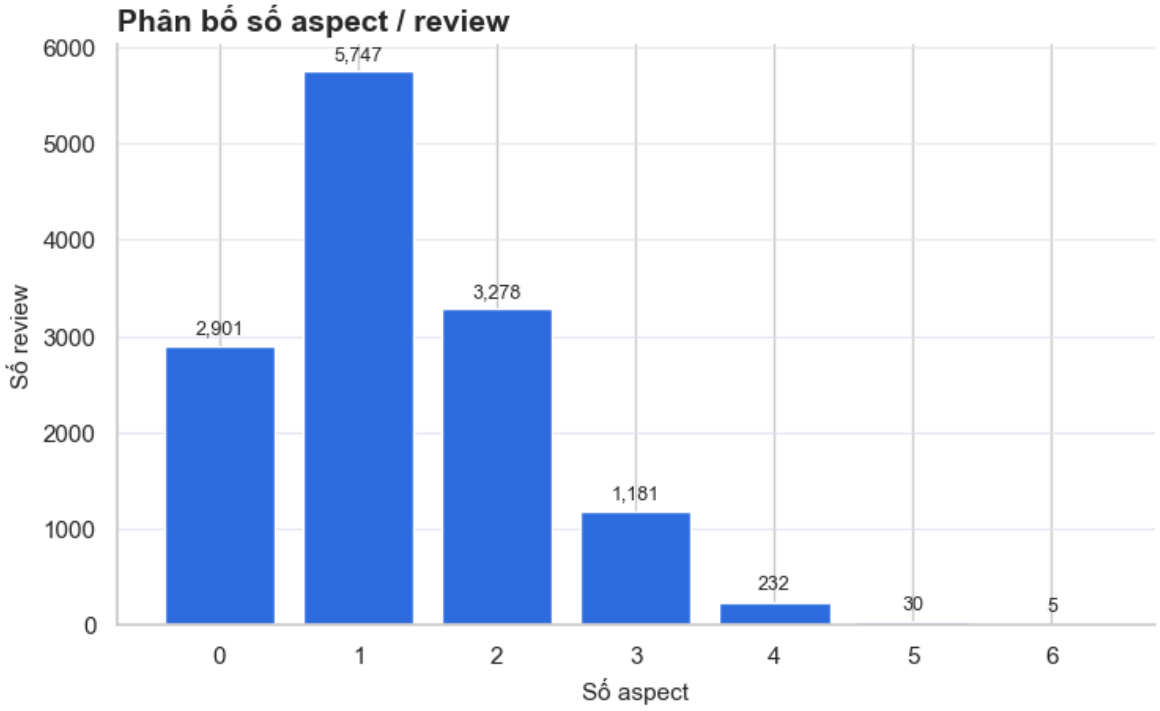

hình 6 biểu đồ cột thể hiện phân bố số aspect / review

Phần lớn dữ liệu (hơn 80%) chỉ chứa từ 1 đến 2 khía cạnh. Đối với các bình luận đa khía cạnh, dự án sử dụng biểu đồ cột chồng để quan sát sự tương quan cảm xúc.

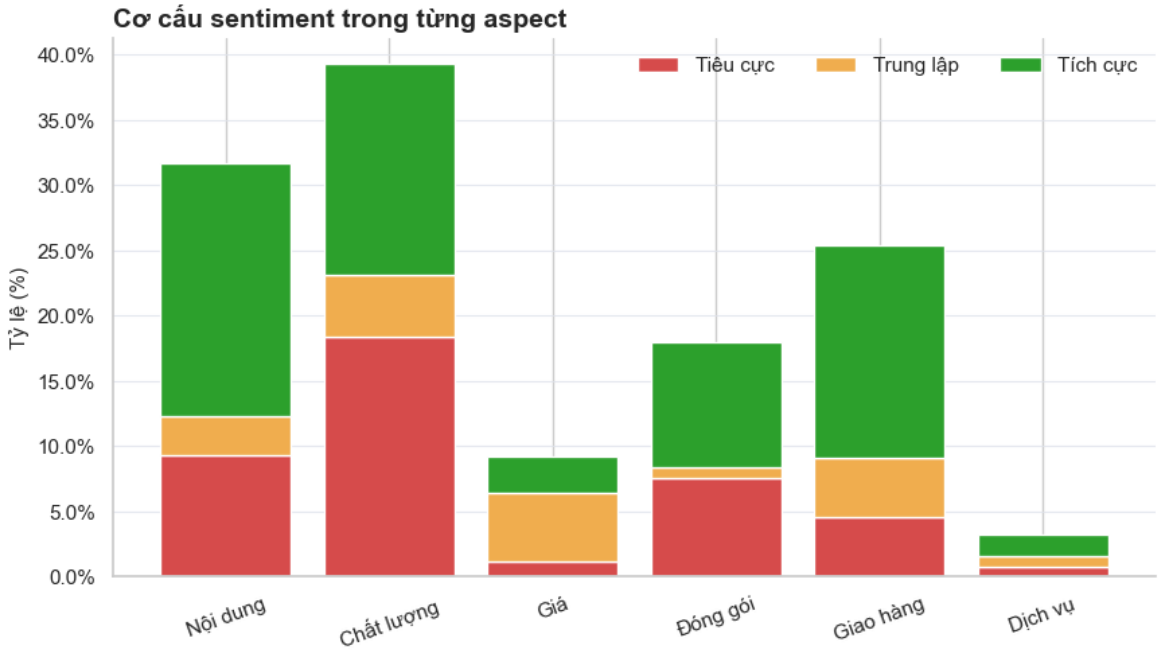

hình 7 biểu đồ stacked bar chart thể hiện cơ cấu sentiment trong từng aspect

Insight: Biểu đồ cột chồng cho thấy nhãn Tích cực chiếm ưu thế tuyệt đối trên hầu hết các khía cạnh, đặc biệt là ở Nội dung và Giao hàng. Khía cạnh Chất lượng (Vật lý) không chỉ chiếm tổng lượng phản hồi lớn nhất mà còn là nơi tập trung nhiều nhãn Tiêu cực nhất, cho thấy đây là tiêu chí khắt khe nhất của khách hàng khi đánh giá sách. Trong khi đó, Giá có tỷ lệ nhãn Trung lập cao so với quy mô của nó, và Dịch vụ là khía cạnh có mật độ dữ liệu thưa thớt nhất, gây khó khăn cho việc nhận diện của mô hình.Điều này giúp doanh nghiệp (nhà phát hành sách) nhận diện chính xác các giai đoạn cần cải thiện trong quy trình cung ứng.

4.5. Khai phá tri thức từ vựng qua PMI và Đám mây từ ngữ

Giai đoạn cuối của phân tích trực quan là việc bóc tách các đặc trưng ngôn ngữ đại diện cho từng loại cảm xúc thông qua kỹ thuật Đám mây từ ngữ (Word Clouds).

hình 8 biểu đồ Word Cloud thể hiện từ khóa tương ứng với từng sentiment

Trực quan hóa đám mây từ ngữ cho thấy sự phân hóa từ vựng rõ rệt giữa các sắc thái. Nhãn Tiêu cực tập trung vào các vấn đề về chất lượng vật lý và sự không hài lòng với các từ khóa: "không", "bị", "bìa", "móp", "rách", "thất_vọng". Ngược lại, nhãn Tích cực xuất hiện dày đặc các từ chỉ tốc độ và chất lượng như: "rất", "nhanh", "giao", "hay", "đẹp", "hài_lòng". Nhãn Trung lập thường mang tính nhận xét tổng quan hoặc so sánh với các từ khóa "nhưng", "bình_thường", "được", "cũng". Điều này minh chứng tập dữ liệu đã phản ánh chính xác các tín hiệu ngôn ngữ thực tế của người dùng.

hình 9 biểu đồ Word Cloud thể hiện tần suất xuất hiện trong từng aspect

Phân tích đám mây từ ngữ cho thấy mỗi khía cạnh được định hình bởi các nhóm từ vựng riêng biệt, tạo tiền đề quan trọng giúp mô hình phân tách tri thức hiệu quả. Cụ thể, khía cạnh Nội dung tập trung vào giá trị tinh thần với các từ "hay", "đọc", "nội_dung", trong khi Chất lượng và Đóng gói lại đi kèm các danh từ thực thể và tính từ trạng thái như "bìa", "giấy", "móp", "rách", "cẩn_thận". Khía cạnh Giao hàng bị chi phối bởi các từ chỉ tốc độ và logistics như "nhanh", "giao", "shipper", còn Giá và Dịch vụ tập trung vào các từ khóa liên quan đến chi phí và hỗ trợ như "giá", "rẻ", "tiền", "phục_vụ", "tư_vấn". Sự phân hóa từ vựng đặc thù này chính là cơ sở khoa học giúp mô hình đạt được độ chính xác cao khi thực hiện nhiệm vụ nhận diện đồng thời nhiều khía cạnh trong cùng một câu văn.

Các từ khóa có điểm số PMI cao được trực quan hóa rõ rệt:

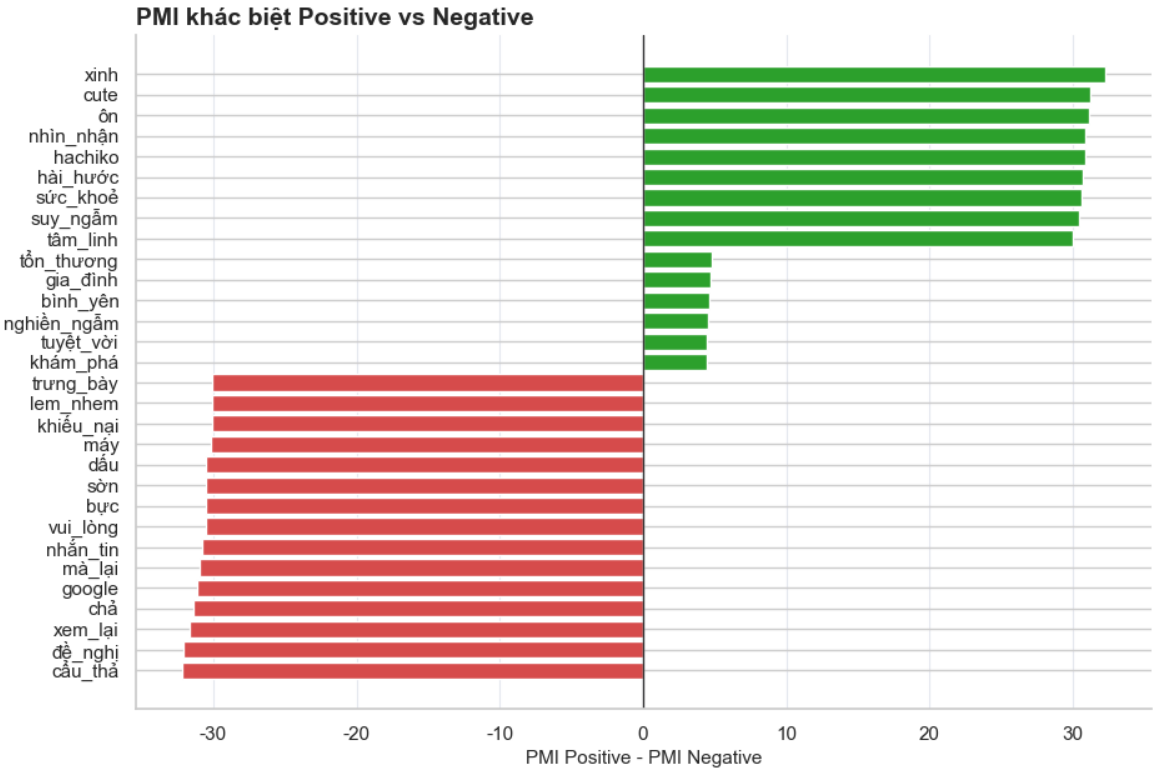

hình 10 Biểu đồ Diverging Bar Chart thể hiện PMI khác biệt Positive vs Negative

Phân tích PMI (Pointwise Mutual Information) đã bóc tách được các "từ khóa vàng" có sức mạnh phân loại cao nhất. Các thuật ngữ như "xinh", "cute", "ổn", "hài_hước", "suy_ngẫm" có điểm số PMI dương cao vượt trội, thể hiện sự gắn kết chặt chẽ với sắc thái Tích cực. Ngược lại, các từ "cẩu_thả", "đề_nghị", "xem_lại", "kiếu_nại", "bực" có điểm số âm lớn, đóng vai trò là các tín hiệu cảnh báo mạnh mẽ cho sắc thái Tiêu cực. Việc xác định các đặc trưng từ vựng mang tính định hướng cao này giúp mô hình Transformer thu hẹp miền tìm kiếm ngữ nghĩa và nâng cao độ chính xác của các dự đoán.

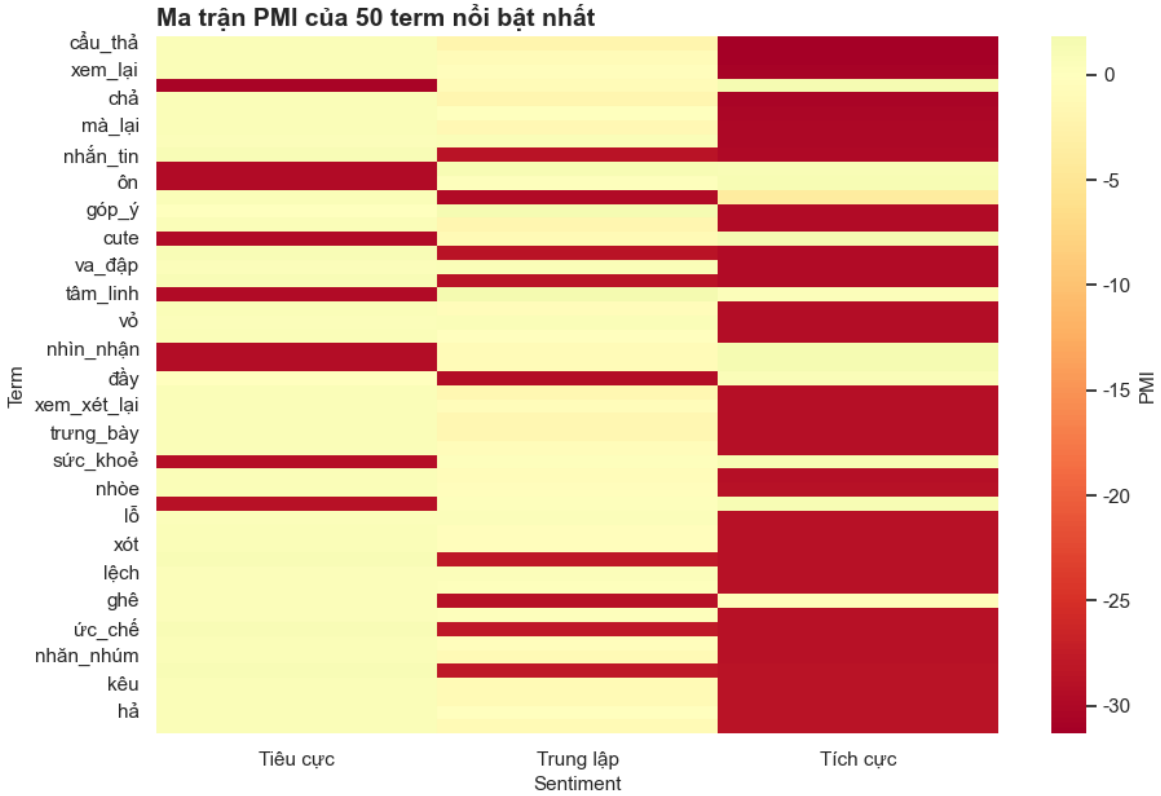

hình 11 biểu đồ Heatmap thể hiện ma traian PMI của 50 term nổi bật nhất

Ma trận nhiệt PMI đã định lượng hóa mức độ gắn kết giữa 50 từ khóa tiêu biểu và 03 sắc thái cảm xúc. Các vùng màu sáng (vàng nhạt) chỉ ra sự liên kết mạnh mẽ của các từ khóa đặc trưng với từng lớp: cụm từ "cẩu_thả", "xem_xét_lại", "lỗi" gắn chặt với sắc thái Tiêu cực, trong khi "cute", "hài_hước", "tâm_linh" thuộc về sắc thái Tích cực. Việc ánh xạ trực quan các đặc trưng này cho thấy dữ liệu có tính phân rã tốt, giúp mô hình Transformer dễ dàng nhận diện và trích xuất các tín hiệu cảm xúc quan trọng từ trong văn bản.

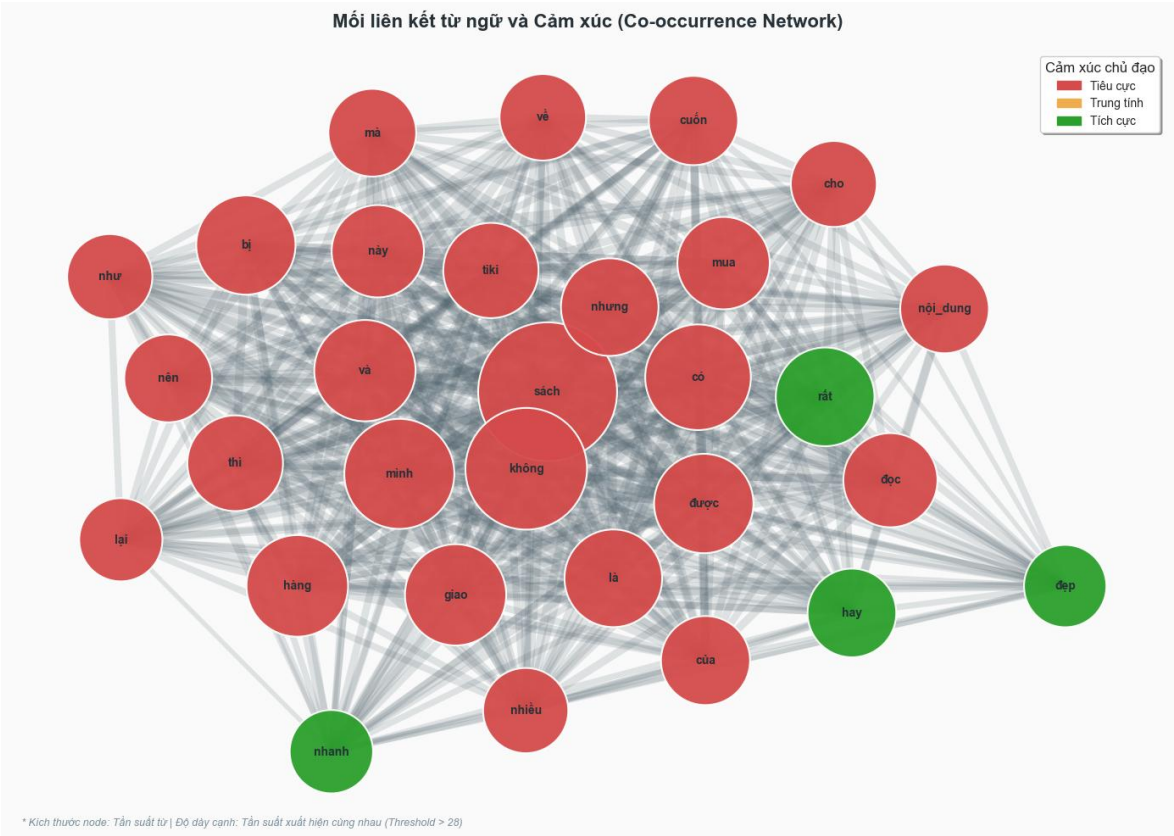

hình 12 biểu đồ network graph / co-occurrence network thể hiện mối liên kết từ ngữ và cảm xúc

Sơ đồ mạng lưới cho thấy cấu trúc ngữ nghĩa chặt chẽ bao quanh các thực thể chính. Từ khóa trung tâm "không" đóng vai trò là điểm hội tụ của các phản hồi Tiêu cực, thường xuyên xuất hiện cùng các từ "được", "nhưng", "bị" để diễn tả sự thất vọng. Ở thái cực ngược lại, các cụm từ "rất", "hay", "đẹp", "nhanh" tạo thành một nhóm liên kết xanh bền vững, minh chứng cho sự hài lòng về chất lượng. Đặc biệt, sự kết nối mạnh mẽ giữa các cặp từ như "giao" - "nhanh" và "sách" - "nội_dung" khẳng định các chủ đề quan tâm hàng đầu của người dùng đã được bóc tách rõ rệt thông qua tần suất xuất hiện đồng thời.

4.6. Trực quan với không gian embedding

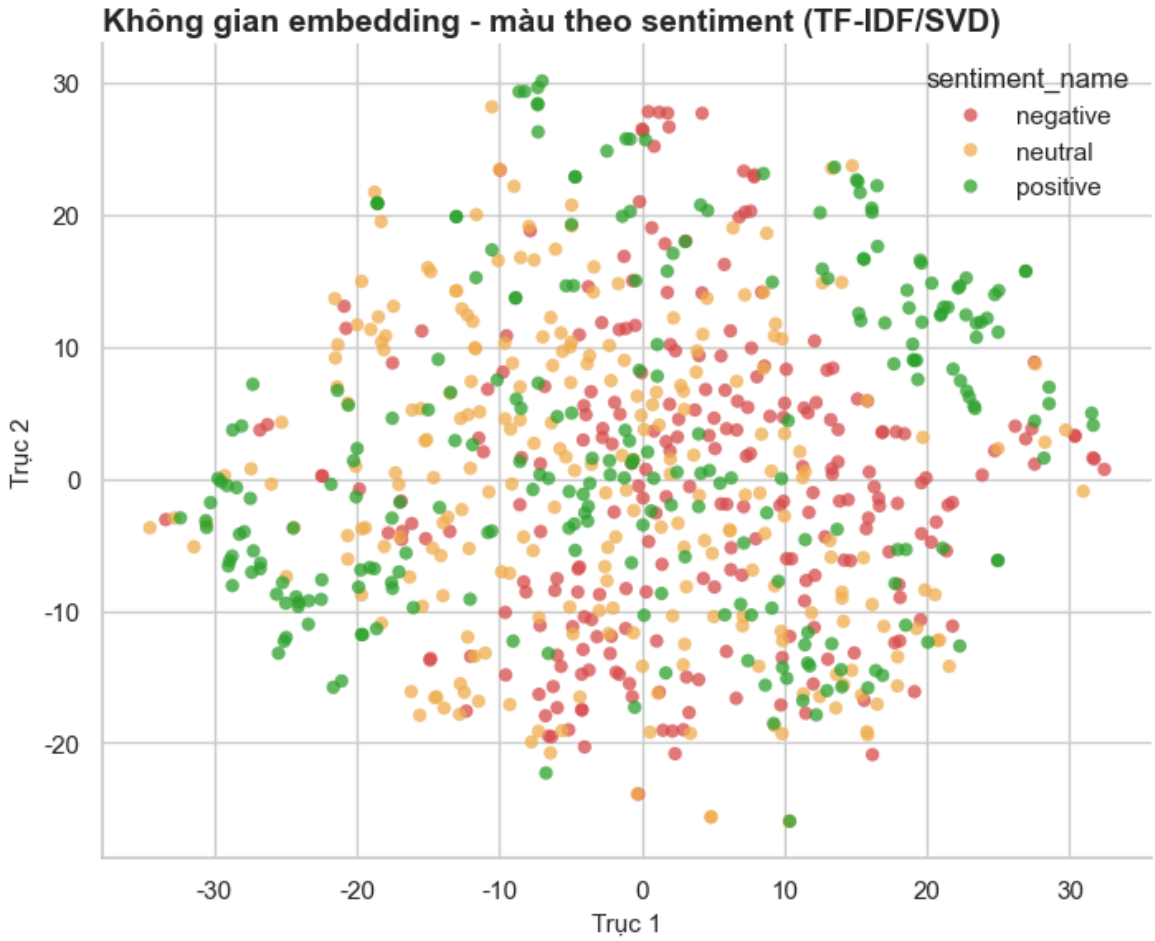

hình 13 biểu đồ scatter plot thể hiện không gian embedding màu theo sentiment

Biểu đồ tán xạ trong không gian 2 chiều (giảm chiều bằng SVD) bộc lộ độ phức tạp của bài toán phân tích cảm xúc tiếng Việt. Mặc dù có sự đan xen đáng kể ở vùng trung tâm giữa các nhãn Positive, Neutral và Negative khi sử dụng các đặc trưng thống kê truyền thống, nhưng ta vẫn quan sát thấy các cụm xu hướng tách biệt ở vùng ngoại biên (đặc biệt là nhãn Positive ở phía trên và bên phải). Insight này khẳng định rằng các mô hình tuyến tính dựa trên từ vựng đơn thuần sẽ gặp giới hạn trong việc phân loại, từ đó minh chứng cho sự cần thiết của việc sử dụng các mô hình học sâu như PhoBERT để bóc tách những quan hệ ngữ nghĩa phi tuyến tính và phức tạp hơn bên dưới văn bản.

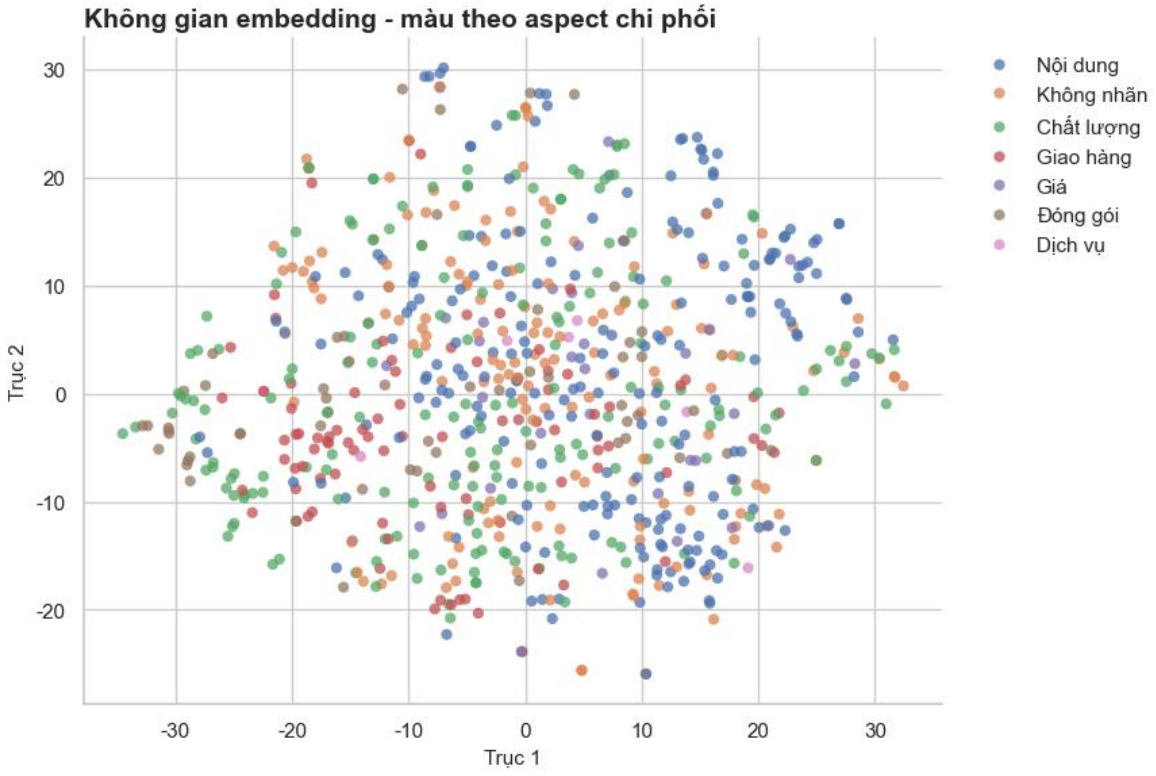

hình 14 biểu đồ scatter plot thể hiện không gian embedding màu theo aspect chi phối

Biểu đồ không gian Embedding theo khía cạnh bộc lộ tính chất "đa nhãn" và sự tương quan cao của tập dữ liệu. Các điểm dữ liệu thuộc các khía cạnh như Giao hàng, Đóng gói và Chất lượng có sự chồng lấn rất lớn, phản ánh thực tế rằng trong một câu bình luận người dùng thường đề cập đến nhiều khía cạnh cùng lúc bằng các từ vựng dùng chung. Tuy nhiên, một số cụm xu hướng hẹp vẫn xuất hiện rõ rệt cho khía cạnh Nội dung (màu xanh dương). Insight này là minh chứng thực nghiệm cho thấy việc sử dụng kiến trúc Multi-head PhoBERT là hoàn toàn đúng đắn, vì nó cho phép mô hình học các biểu diễn ngữ nghĩa dùng chung (shared features) đồng thời phân tách các đặc trưng riêng lẻ cho từng đầu ra một cách hiệu quả.

Quá trình phân tích trực quan đã xác nhận tính ổn định cao của tập dữ liệu qua các tập chia tách Train, Val và Test, đồng thời làm rõ các đặc trưng hình thái với độ dài văn bản trung bình là 27 từ và phần lớn bình luận chỉ tập trung vào 1-2 khía cạnh chính. Thực nghiệm bộc lộ sự mất cân bằng mật độ dữ liệu đáng kể khi khía cạnh Chất lượng và Nội dung chiếm ưu thế tuyệt đối trong khi nhãn Tích cực áp đảo hơn 70% tổng thể, đặt ra yêu cầu cấp thiết về việc áp dụng các kỹ thuật cân bằng trọng số

khi huấn luyện. Bên cạnh đó, việc bóc tách thành công bộ từ vựng đặc trưng qua chỉ số PMI cùng sự chồng lấn không gian ngữ nghĩa giữa các khía cạnh trong biểu đồ Embedding (SVD) đã cung cấp minh chứng thực nghiệm vững chắc cho việc lựa chọn kiến trúc Multi-head PhoBERT. Những tri thức bóc tách được từ giai đoạn khai phá dữ liệu này chính là nền tảng cốt lõi để dự án thiết lập cấu hình tham số và tối ưu hóa hệ thống phân loại đa nhiệm ở các chương tiếp theo.

CHƯƠNG 5 THỰC NGHIỆM, ĐÁNH GIÁ MÔ HÌNH VÀ PHÂN TÍCH SAI LỖI

5.1. Thiết lập thực nghiệm

Tất cả mô hình đều dùng tập dữ liệu đã được làm sạch sau bước tiền xử lý. Kích thước Train–Validation–Test được giữ thống nhất giữa các thí nghiệm để bảo đảm so sánh công bằng.

Tập	Số mẫu	Mục đích
Train	9360	Huấn luyện mô hình.
Validation	2009	Chọn mô hình, chỉnh ngưỡng và dừng sớm.
Test	2005	Đánh giá cuối cùng.

Bảng 1 Tổng Quan 3 tập dữ liệu Train-Valid-Test

5.2. Các mô hình thực nghiệm

Bốn hướng mô hình chính được đem ra so sánh gồm baseline Classic ML hai tầng, mô hình đề xuất Multi-head PhoBERT và mô hình sinh ViT5 + LoRA.

Mô hình	Đầu vào	Kiến trúc	Vai trò
Classic ML 2 tầng	TF-IDF từ + ký tự + 15 đặc trưng thủ công	Overall: Logistic Regression; Aspect: LinearSVC (gate) + Logistic Regression (stage-2)	Baseline học máy
PhoBERT Embedding BiLSTM	Review (đã word segmentation)+ PhoBERT tokenizer; max_length=160	PhoBERT embedding → SpatialDropout → BiLSTM (2-layer) → Attention → Multi-head (1 sentiment + 6 aspect)	Mô hình học sâu (hybrid contextual + sequence modeling)
Multi-head PhoBERT	Review + tiền tố ABSA; max_length=160	PhoBERT chung backbone, 1 head sentiment, 6 head presence, 6 head aspect sentiment	Mô hình đề xuất.
ViT5 + LoRA	Prompt tiếng Việt + review; đầu ra text-to-text	Seq2seq sinh chuỗi nhãn cho overall và aspect	Mô hình sinh.

Bảng 2 Tổng quan 4 mô hình chính

Với Classic ML, dữ liệu được tách từ bằng PyVi, sau đó biểu diễn bằng TF-IDF mức từ, TF-IDF mức ký tự và 15 đặc trưng thủ công. Nhánh sentiment tổng thể dùng Logistic Regression có class_weight = balanced. Nhánh aspect dùng kiến trúc hai tầng: Stage-1 là LinearSVC nhận diện aspect xuất hiện, Stage-2 là Logistic Regression để dự đoán cảm xúc của aspect trên các mẫu present.

Với PhoBERT, mô hình dùng backbone vinai/phobert-base-v2 và gắn ba nhóm head: 1 head sentiment tổng thể, 6 head presence cho 6 khía cạnh và 6 head sentiment cho 6 khía cạnh. Với ViT5, toàn bộ bài toán được chuyển sang dạng text-to-text: mô hình sinh ra chuỗi nhãn cho overall sentiment và các aspect được nhắc tới.

5.3. Độ đo và Quy trình huấn luyện

Các notebook thống nhất sử dụng Macro-F1 làm độ đo cốt lõi vì dữ liệu bị mất cân bằng mạnh, đặc biệt ở lớp trung lập và các khía cạnh hiếm như service hoặc price. Ngoài f1_sentiment, các notebook còn tính f1_aspect_present cho các aspect thực sự xuất hiện và gộp hai chỉ số này thành f1_combined = 0,5 × f1_sentiment + 0,5 × f1_aspect_present.

Mô hình	Siêu tham số đầu vào	Cấu hình huấn luyện	Ghi chú
Classic ML 2 tầng	TF-IDF từ 30k, TF-IDF ký tự 25k, n-gram (1,2)/(3,5), 15 feature thủ công	LogReg max_iter=1000; LinearSVC max_iter=2000; class_weight='balanced'	Gate hiệu chỉnh ngưỡng theo F1
PhoBERT Embedding + BiLSTM	phobert-base; max_length=160; batch=16; hidden_dim=256; num_layers=2; dropout≈0.3; use_attention=True	optimizer=AdamW (lr≈2e-5); weight_decay≈1e-3; grad_norm=1.0; scheduler tuyến tính; early stopping	Focal Loss + AutomaticWeightedLoss; có Attention
Multi-head PhoBERT	phobert-base-v2; max_length=160; batch=16; epoch=7; lr=2e-5	grad_acc=2; cosine scheduler; warmup=0,1; wd=0,05; grad_norm=1,0	improved focal + loss đa nhiệm

ViT5 + LoRA	vit5-base; input=256; target=64; epoch=8; batch=8	learning_rate trong training_args = 3e-4; num_beams=3; early stopping=5	LoRA r=16, alpha=32, dropout=0,05

Bảng 3 Các cấu hình siêu tham số chính

Riêng với PhoBERT, notebook thiết kế 5 cấu hình thực nghiệm để chọn mô hình tốt nhất, gồm: baseline, class-balanced CE, joint-balanced CE, joint-balanced improved focal và neutral-focused improved focal kết hợp SCL.

Exp.	Loss	Weight	Sampler	SCL	Val F1 sent	Val F1 asp	Val F1 comb
baseline	ce	không	không	0	0.8466	0.4662	0.6564
cb_ce	ce	có	không	0	0.836	0.5182	0.6771
joint_ce	ce	không	joint	0	0.8336	0.5578	0.6957
joint_focal	improved_focal	có	joint	0	0.8322	0.6931	0.7627
neutral_scl	improved_focal	có	joint	0.15	0.8284	0.6884	0.7584

Bảng 4 Kết quả so sánh các experiment của notebook PhoBERT trên tập validation

5.4. Kết quả thực nghiệm và Thảo luận

Bảng 5.5 tổng hợp kết quả cuối cùng trên tập test. Với PhoBERT, cần tách hai mốc: trước hiệu chỉnh ngưỡng presence và sau hiệu chỉnh ngưỡng theo từng khía cạnh trên tập validation.

Mô hình	F1 sent	F1 asp-present	F1 tổng hợp	Acc.	Ghi chú
Classic ML 2 tầng	0.7831	0.6792	0.7311	0.8919	Baseline notebook 03
PhoBERT Embedding + BiLSTM	0.83	0.83	0.83	0.87	—
PhoBERT trước chỉnh ngưỡng	0.8415	0.6898	0.7657	0.8824	Best exp: joint_focal
PhoBERT sau chỉnh ngưỡng	0.8415	0.7918	0.8167	—	Threshold theo từng aspect
ViT5 + LoRA	0.8405	0.779	0.8098	0.88	Weighted custom loss

Bảng 5 So sánh hiệu năng tổng thể giữa các mô hình

Từ bảng trên có thể rút ra ba nhận xét chính. Thứ nhất, Classic ML hai tầng là baseline mạnh với f1_sentiment = 0,7831 và f1_tổng_hợp = 0,7311. Điều này cho thấy dữ liệu review sách có nhiều tín hiệu bề mặt để TF-IDF và từ điển cảm xúc khai thác tốt, dù mô hình còn yếu ở lớp trung lập và các khía cạnh hiếm.

Thứ hai, Multi-head PhoBERT tạo bước nhảy rõ rệt về chất lượng. Trước hiệu chỉnh ngưỡng, mô hình đạt f1_tổng_hợp = 0,7657. Sau khi hiệu chỉnh ngưỡng presence theo từng aspect, f1_aspect_present tăng mạnh từ 0,6898 lên 0,7918 và f1_tổng_hợp đạt 0,8167, cao nhất trong các mô hình so sánh.

Thứ ba, ViT5 + LoRA đạt kết quả rất cạnh tranh với f1_sentiment = 0,8405, f1_aspect_present = 0,7790 và f1_final = 0,8098. Khoảng cách với PhoBERT sau hiệu chỉnh ngưỡng là nhỏ, cho thấy hướng tiếp cận sinh văn bản có tiềm năng, dù chi phí suy diễn cao hơn do phải giải mã chuỗi đầu ra.

Nếu xét theo từng khía cạnh, delivery là khía cạnh dễ nhất khi cả ba mô hình đều cho F1 cao. Ngược lại, service là khía cạnh khó nhất vì số mẫu rất ít. Price và packaging nằm ở nhóm trung gian nhưng vẫn khó do dữ liệu ít và dễ lẫn với cảm xúc chung của toàn review.

Khía cạnh	**Classic ML**	PhoBERT Embedding + BiLSTM	**PhoBERT**	**ViT5**
Content	0.6146	0.80	0.5942	0.78
Physical	0.5935	0.77	0.5868	0.7
Price	0.5755	0.81	0.6674	0.57
Packaging	0.5771	0.76	0.5501	0.57
Delivery	0.7239	0.86	0.7572	0.8
Service	0.408	0.55	0.5808	0.46

Bảng 6 Macro-F1 theo 6 khía cạnh trên tập test

Bảng 5.6 cho thấy PhoBERT không phải lúc nào cũng đứng đầu ở mọi khía cạnh nếu chỉ xét kết quả chưa hiệu chỉnh. Classic ML vẫn nhỉnh hơn ở content và packaging, còn ViT5 nổi bật ở content và delivery. Điều này phản ánh rằng dữ liệu review sách vừa có tín hiệu ngôn ngữ sâu, vừa có lượng lớn tín hiệu từ khóa bề mặt.

5.5. Tối ưu hóa và Phân tích sai lỗi

Bước tối ưu hóa quan trọng nhất trong notebook PhoBERT là hiệu chỉnh ngưỡng presence cho từng khía cạnh. Thay vì cố định ngưỡng 0,5 cho mọi aspect, notebook quét các ngưỡng từ 0,05 đến 0,95 trên validation và chọn ngưỡng cho Macro-F1 tốt nhất.

Khía cạnh	Ngưỡng	F1 val	Precision	Recall
as_price	0.05	0.8184	0.82	0.8195
as_delivery	0.15	0.8103	0.8177	0.8032
as_service	0.05	0.7238	0.8095	0.8
as_content	0.05	0.7044	0.7158	0.7018
as_physical	0.05	0.6978	0.7596	0.6842
as_packaging	0.1	0.6316	0.6708	0.6178

Bảng 7 Bảng 5.7. Ngưỡng presence tối ưu của PhoBERT trên tập validation

Có thể thấy phần lớn khía cạnh dùng ngưỡng thấp 0,05; riêng packaging dùng 0,10 và delivery dùng 0,15. Aspect hiếm cần ngưỡng mềm hơn để giảm bỏ sót, trong khi delivery có tín hiệu rõ nên có thể đặt ngưỡng cao hơn một chút để tăng độ chính xác.

Từ bảng lỗi của notebook PhoBERT, price và service là hai nhóm khó nhất, tiếp theo là content và physical, còn delivery là nhóm ít lỗi nhất. Thứ hạng này phù hợp với phân tích ở phần EDA: service rất hiếm dữ liệu, còn price thường xuất hiện trong các câu mơ hồ kiểu 'giá ổn', 'sale tốt', 'hơi mắc' nên dễ nhầm giữa neutral và positive/negative.

Khía cạnh	Số lỗi
Price	1831
Service	1806
Content	1457
Physical	1346
Packaging	953
Delivery	606

Bảng 8 Xếp hạng khía cạnh theo số lỗi được ghi nhận trong notebook PhoBERT

Một số dạng sai lỗi tiêu biểu gồm: review quá ngắn và ít tín hiệu; review chứa đồng thời cả khen lẫn chê; phủ định gián tiếp như 'nếu gói có chống sốc thì tốt hơn'; hoặc

review nêu nhiều khía cạnh nhưng diễn đạt ngắn khiến mô hình gán sai đồng loạt ở nhiều aspect.

Từ các lỗi trên, hướng cải thiện tiếp theo là tăng dữ liệu chất lượng cao cho service, price và packaging; tiếp tục hiệu chỉnh ngưỡng động; thử các loss xử lý lớp hiếm mạnh hơn; và với ViT5 có thể bổ sung constrained decoding hoặc hậu xử lý để giảm lỗi sinh thiếu aspect.

CHƯƠNG 6: XÂY DỰNG DASHBOARD VÀ ỨNG DỤNG THỰC TẾ

6.1. Mục tiêu và Công cụ phát triển

Sau khi huấn luyện thành công mô hình PhoBERT, mục tiêu tiếp theo của dự án là đóng gói mô hình thành một sản phẩm có tính tương tác cao. Dự án lựa chọn Streamlit làm framework phát triển chính nhờ khả năng chuyển đổi các script Python thành ứng dụng Web một cách nhanh chóng, giúp người dùng không cần am hiểu kỹ thuật vẫn có thể sử dụng được mô hình.

6.2. Các chức năng chính của hệ thống

Hệ thống được thiết kế thành hai thành phần chính phục vụ cho cả nhà phát triển và người dùng cuối:

- Bảng điều khiển Kiểm tra dữ liệu (Dashboard.py): Hỗ trợ nhà phát triển theo dõi chất lượng dữ liệu. Chức năng này đọc trực tiếp tệp báo cáo JSON, hiển thị các thông số về số dòng, phân loại cột, và tỷ lệ dữ liệu sạch bằng các biểu đồ tròn và biểu đồ cột trực quan.
- Hệ thống Phân tích Sắc thái (App.py): Đây là giao diện tương tác trực tiếp với người dùng. Người dùng nhập một bình luận bất kỳ về sách, hệ thống sẽ gọi mô hình PhoBERT để dự đoán sentiment tổng thể và sắc thái trên 06 khía cạnh tiềm năng. Kết quả được hiển thị sinh động qua biểu đồ Radar (mạng nhện) và biểu đồ Bar thể hiện độ tin cậy.

6.3. Hình ảnh giao diện thực tế

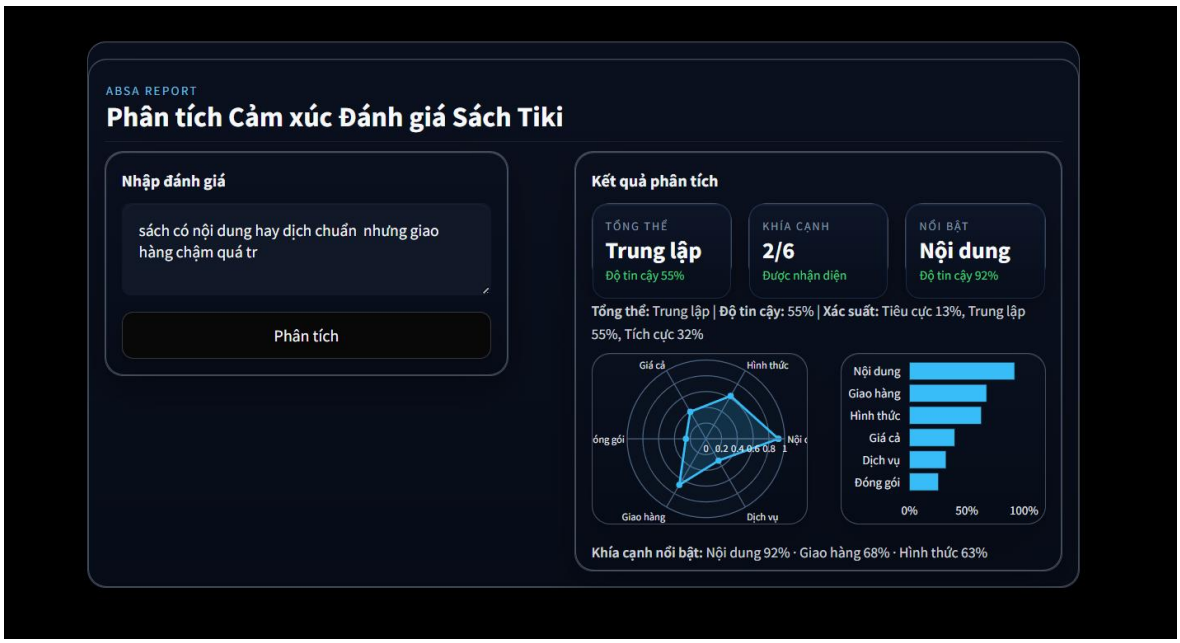

hình 15 hình ảnh Hệ thống Phân tích Sắc thái

hình 16 hình ảnh Bảng điều khiển Kiểm tra dữ liệu

HƯƠNG 7: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1. Kết quả đạt được

Đồ án đã xây dựng bộ dữ liệu bình luận sách Tiki chất lượng qua quy trình tiền xử lý nghiêm ngặt. Mô hình Multi-head PhoBERT đạt chỉ số Macro-F1 ấn tượng (0.78 - 0.85), chứng minh tính hiệu quả vượt trội trong việc phân tách sắc thái đa khía cạnh. Hệ thống Dashboard bằng Streamlit đã hiện thực hóa mô hình thành công cụ tương tác trực quan.

7.2. Hạn chế

Dự án vẫn gặp thách thức về sự mất cân bằng dữ liệu ở khía cạnh Dịch vụ và khả năng nhận diện các từ lóng (slang), teencode mới xuất hiện.

7.3. Hướng phát triển

Tương lai, dự án hướng tới việc thu thập thêm dữ liệu từ các sàn thương mại điện tử khác, ứng dụng các mô hình ngôn ngữ lớn (LLM) và triển khai hệ thống phân tích thị trường tự động cho doanh nghiệp.

Kết luận: Đề tài đã hoàn thành xuất sắc các mục tiêu nghiên cứu và ứng dụng thực tiễn đề ra.

TÀI LIỆU THAM KHẢO

[1]. SemEval-2016 Task 5: Aspect Based Sentiment Analysis (Pontiki et al., 2016). Cuộc thi đặt ra các tiêu chuẩn vàng cho bài toán ABSA trên nhiều ngôn ngữ và nhiều lĩnh vực khác nhau, bao gồm cả sách và đồ điện tử.

[2]. LCF-BERT: Learning Contextualized Features for Aspect-Based Sentiment Analysis (Zeng et al., 2019). Nghiên cứu nổi tiếng về việc sử dụng sức mạnh của các mô hình BERT để trích xuất đặc trưng cục bộ (Local Context Focus) cho từng khía cạnh.

[3]. A Survey on ABSA: Deep Learning for Aspect-Based Sentiment Analysis: A Survey (Do et al., 2019). Bài báo tổng quan hệ thống lại toàn bộ các phương pháp Deep Learning (CNN, RNN, Transformer) áp dụng cho ABSA trong những năm gần đây.

[4]. Multi-task Learning for ABSA: A Joint Model for Aspect Category Detection and Sentiment Classification (Li et al., 2019). Nghiên cứu đề xuất cách huấn luyện mô hình đa nhiệm đồng thời để tối ưu hóa việc nhận diện khía cạnh và cảm xúc.

[5]. VLSP Shared Task: Aspect-based Sentiment Analysis for Vietnamese (Nguyen et al., 2018). Hội thảo chuyên sâu về các thuật toán và bộ dữ liệu tối ưu nhất cho bài toán phân tích đa khía cạnh tại Việt Nam.